Chapitre 1

Résolutions des systèmes linéaires

Dans ce chapitre, on s'intéresse à la résolution numérique d'un système linéaire.

Définition 1.1 *Un système linéaire de m équations à n inconnues $x_1, x_2, ...x_n$, s'écrit sous forme matricielle, $Ax = b$ où A est une matrice comportant m lignes et n colonnes, x est le vecteur colonne dont les composantes sont les x_i et b, le second membre, est aussi un vecteur colonne avec n composantes. Le vecteur x est appelé solution du système.*

Exemple 1.1 *Le système suivant de 4 équations à 3 inconnues*

$$\begin{cases} x_1 - 2x_2 + 3x_3 = -1 \\ x_1 + x_3 = 7 \\ 2x_1 + 3x_2 - 5x_3 = 3 \\ -5x_1 + 2x_2 + 4x_3 = 0 \end{cases} \quad s'écrit \quad \begin{pmatrix} 1 & -2 & 3 \\ 1 & 0 & 1 \\ 2 & 3 & -5 \\ -5 & 2 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -1 \\ 7 \\ 3 \\ 0 \end{pmatrix}.$$

La matrice a 4 lignes et 3 colonnes, le second membre a 4 composantes et le vecteur solution a 3 composantes qui sont les 3 inconnues du système (dans ce cas, $m \neq n$).

On considère alors, la résolution du système linéaire

$$Ax = b, \tag{1.1}$$

où A est une matrice carrée d'ordre n, supposée inversible, b est un vecteur de $\mathbb{R}^n$ et x est le vecteur des inconnues.

Théoriquement, le fait que A soit inversible entraîne que le système (1.1) admet une solution unique $x = A^{-1}b$, mais cette écriture suppose que l'on dispose de la matrice A^{-1}, mais l'obtention de A^{-1} est équivalente à la résolution de n systèmes linéaires, en plus de la multiplication $x = A^{-1}b$.Une autre méthode consisterait à obtenir les x_i à l'aide des formules de Cramer, c'est à dire,

$$x_i = \frac{\det A_i}{\det A}, \ i = 1, ...n.$$

où A_i, est la matrice obtenue en remplaçant la $i - ème$ colonne de A par le vecteur b. Ces formules nécessitent le calcul de plusieurs déterminants, du fait que le nombre d'opérations nécessaires pour le calcul d'un déterminant pour un système d'ordre n est de l'ordre de $n!$, ainsi, au total on aura, $(n+1)!n$ multiplications, $(n+1)(n!-1)$ additions et n divisions. Ce nombre devient impossible à réaliser lorsque n est grand, alors la méthode de Cramer et les méthodes similaires s'avèrent inutilisables. Il faut donc développer des méthodes alternatives avec un coût (ou nombre d'opérations) raisonnable.

Les méthodes numériques de résolution d'un système linéaire sont de deux types :

- **Méthodes directes :** qui déterminent explicitement la solution, après un nombre fini d'opérations arithmétiques, on peut alors en déduire le temps de calcul nécessaire à la résolution (qui peut être très long si n est grand).
- **Méthodes itératives :** qui génèrent une suite qui converge vers la solution du système linéaire.

1.1 Méthodes directes

1.1.1 Résolution des systèmes triangulaires.

On rappelle qu'une matrice $A = (a_{ij})_{1\leq i,j\leq n}$ est triangulaire supérieure (respectivement triangulaire inférieure) si $i > j \Longrightarrow a_{ij} = 0$ (respectivement $i < i \Longrightarrow a_{ij} = 0$), alors, si la matrice A de (1.1) est triangulaire supérieure (resp. triangulaire inférieure), on dira que le système linéaire (1.1) est un système triangulaire supérieur (resp. triangulaire inférieur), ainsi :

- Si A est une matrice triangulaire inférieure, alors la résolution de (1.1), se fait par déscente, ce qui veut dire
$$x_1 = \frac{b_1}{a_{11}},$$
ensuite, on déduit les inconnues $x_2, x_3, ...x_n$ grâce à la relation
$$x_i = \frac{1}{a_{ii}}\left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j\right).$$
- Si A est une matrice triangulaire supérieure, alors la résolution de (1.1), se fait par remontée, et donc
$$x_n = \frac{b_n}{a_{nn}},$$
on déduit alors les inconnues $x_{n-1}, x_{n-2}, ...x_1$ grâce à la relation
$$x_i = \frac{1}{a_{ii}}\left(b_i - \sum_{j=i+1}^{n} a_{ij}x_j\right).$$

1.1.2 Méthode d'élimination de Gauss

Le principe de cette méthode, dite aussi méthode du pivot de Gauss, est de transformer le système(1.1) en $(MA)x = Mb$ où MA est une matrice triangulaire supérieure sans calculer explicitement M. C'est donc de se ramener, par des opérations élémentaires sur les lignes et sur les colonnes du système (1.1), à la résolution d'un système triangulaire supérieur. Pour se faire, on construit une suite de matrices

$$A^{(1)} = A,\ A^{(2)},\ ...,\ A^{(n)}$$

et de vecteurs

$$b^{(1)} = b, b^{(2)}, ..., b^{(n)}$$

tels que, la résolution du système $Ax = b$ soit équivalente à celle de $A^{(k)}x = b^{(k)}$ pour tout $k \in \{1, 2, ..., n\}$ où la matrice $A^{(k)}$ est de la forme

$$A^{(k)} = \begin{pmatrix} a_{11}^{(k)} & \cdots & \cdots & \cdots & \cdots & a_{1n}^{(k)} \\ 0 & \ddots & & & & a_{2n}^{(k)} \\ \vdots & \ddots & \ddots & & & \vdots \\ \vdots & & 0 & a_{kk}^{(k)} & \cdots & \\ \vdots & & \vdots & \vdots & & \vdots \\ 0 & \cdots & 0 & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}$$

Il faut donc savoir passer de la $k^{ième}$ étape vers la $(k+1)^{ième}$ étape, en d'autre termes de $A^{(k)}$ à $A^{(k+1)}$. La matrice $A^{(n)}$ est alors obtenue comme l'indique l'algotithme suivant :

Algorithm 1.1 (de triangularisation de Gauss) *La matrice $A^{(k+1)}$ et le vecteur $b^{(k+1)}$ sont construits à partir de $A^{(k)}$ et de $b^{(k)}$ comme suit :*

- *Si $a_{kk}^{(k)} = 0$, on échange les lignes L_k et L_{i_0} de la matrice A et du vecteur b, où i_0 est déterminée par :*

$$\left|a_{i_0 k}^{(k)}\right| = \max_{i>k} \left|a_{ik}^{(k)}\right|. \tag{1.2}$$

- *Si $a_{kk}^{(k)} \neq 0$ alors :*

1- Les k premières lignes restent inchangées, c'est à dire

$$\forall i \in \{1, ..., k\} \quad a_{ij}^{(k+1)} = a_{ij}^{(k)} \quad et\ b_i^{(k+1)} = b_i^{(k)}.$$

2- Sur les lignes L_i suivantes, on fait la bonne combinaison linéaire pour annuler $a_{ik}^{(k+1)}$ tels que $\forall i \in \{k+1, ..., n\}$ et $\forall j \in \{k, ..., n\}$, on a alors

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} a_{kj}^{(k)} \qquad b_i^{(k+1)} = b_i^{(k)} - \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}} b_k^{(k)}.$$

Enfin on résout le système triangulaire supérieur $A^{(n)}x = b^{(n)}$ en remontant c'est à dire

$$x_n = \frac{b_n^{(n)}}{a_{nn}^{(n)}},$$

puis $x_{n-1}, x_{n-2}, ...x_1$ sont obtenus grâce à la relation

$$x_i = \frac{1}{a_{ii}^{(n)}} \left(b_i^{(n)} - \sum_{j=i+1}^{n} a_{ij}^{(n)} x_j^{(n)} \right).$$

Exemple 1.2 *Soit à résoudre le système d'équations $Ax = b$, tel que :*

$$\begin{pmatrix} 1 & 2 & 2 \\ 1 & 3 & -2 \\ 3 & 5 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \\ 8 \end{pmatrix},$$

on pose alors $A = A^{(1)}$*, comme* $a_{11}^{(1)} \neq 0$*, alors la première ligne reste inchangée dans* $A^{(2)}$*, puis la deuxième ligne de* $A^{(2)}$*, est définie par :* $L_2^{(2)} = L_2^{(1)} - L_1^{(1)}$*, ensuite* $L_3^{(2)} = L_3^{(1)} - 3L_1^{(1)}$*, on aura donc*

$$\underbrace{\begin{pmatrix} 1 & 2 & 2 \\ 0 & 1 & -4 \\ 0 & -1 & 2 \end{pmatrix}}_{A^{(2)}} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \underbrace{\begin{pmatrix} 2 \\ -3 \\ 2 \end{pmatrix}}_{b^{(2)}},$$

ensuite, comme $a_{22}^{(2)} \neq 0$*, alors la deuxième ligne reste inchangée dans* $A^{(3)}$*, puis la troisième de* $A^{(3)}$*, est obtenue par* $L_3^{(3)} = L_3^{(2)} + L_2^{(2)}$*, ce qui permet alors d'obtenir le système triangulaire supérieur*

$$\underbrace{\begin{pmatrix} 1 & 2 & 2 \\ 0 & 1 & -4 \\ 0 & 0 & -2 \end{pmatrix}}_{A^{(3)}} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \underbrace{\begin{pmatrix} 2 \\ -3 \\ -1 \end{pmatrix}}_{b^{(3)}}.$$

La méthode de remontée donne ensuite

$$x_3 = \frac{1}{2}, \;\; x_2 = -3 + 4x_3 = -1, \;\; x_1 = 2 - 2x_2 - 2x_3 = 3.$$

Algorithm 1.2 (triangularisation de Gauss avec pivot partiel) *Dans l'algorithme de triangularisation de Gauss de la matrice* A*, le terme* $a_{kk}^{(k)}$ *est appelé pivot. Il est important que ce pivot soit le plus grand possible en valeur absolue, en effet un pivot « petit » peut conduire à des erreurs d'arrondis très importantes comme le montre l'exemple suivant*

Exemple 1.3 *Soit à résoudre le systeme suivant*

$$\begin{pmatrix} 10^{-4} & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

La solution de ce système est $(x_1, x_2) = (1.00010, 0.99999)$*, alors la solution approchée arrondie à* 10^{-3} *près est*

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \simeq \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Si on prend 10^{-4} *comme pivot, on obtient après triangularisation de Gauss le système équivalent*

$$\begin{pmatrix} 10^{-4} & 1 \\ 0 & 10^4 - 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 10^4 - 2 \end{pmatrix}.$$

Alors, avec arrondissement à trois chiffres significatifs on obtient comme solution,

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \simeq \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

Par contre, en prenant 1 *comme pivot, c'est à dire le systeme équivalent suivant*

$$\begin{pmatrix} 1 & 1 \\ 10^{-4} & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix},$$

et en arrondissant à 10^{-3} *près, on obtient,*

$$\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \simeq \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

A travers cet exemple, on voit donc le problème que peut poser un pivot trop petit. Pour éviter de diviser par des pivots trop petits pouvant conduire à des solutions absurdes, on peut adopter automatiquement la stratégie du pivot partiel de la manière suivante

A chaque étape k, on choisit $a_{kk}^{(k)}$ tel que $a_{kk}^{(k)} = \max_{i \geq k} \left| a_{ik}^{(k)} \right|$.

Exemple 1.4 *En utilisant l'algorithme de triangularisation de Gauss avec pivot partiel, résoudre le systeme linéaire d'équations suivant*

$$\left\{ \begin{array}{c} 2x_1 + x_2 + x_3 = 5 \\ 4x_1 - 6x_2 = -2 \\ -2x_1 + 7x_2 + 2x_3 = 9 \end{array} \right. \Longleftrightarrow \underbrace{\begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix}}_{A} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \\ 9 \end{pmatrix},$$

comme $\max_{i \geq k} \left| a_{ik}^{(1)} \right| = 4 = a_{21}^{(1)}$ alors on permute la première ligne de A et la deuxième ligne de A et on aura

$$\underbrace{\begin{pmatrix} 2 & 1 & 1 \\ 4 & -6 & 0 \\ -2 & 7 & 2 \end{pmatrix}}_{A} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 5 \\ -2 \\ 9 \end{pmatrix} \begin{array}{c} L_2^{(1)} \\ \rightleftarrows \\ L_1^{(1)} \end{array} \underbrace{\begin{pmatrix} 4 & -6 & 0 \\ 2 & 1 & 1 \\ -2 & 7 & 2 \end{pmatrix}}_{A^{(1)}} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -2 \\ 5 \\ 9 \end{pmatrix},$$

par suite la deuxième ligne de $A^{(2)}$, est définie par : $L_2^{(2)} = L_2^{(1)} - \frac{1}{2} L_1^{(1)}$, ensuite $L_3^{(2)} = L_3^{(1)} + \frac{1}{2} L_1^{(1)}$, on aura donc

$$\underbrace{\begin{pmatrix} 4 & -6 & 0 \\ 0 & 4 & 1 \\ 0 & 4 & 2 \end{pmatrix}}_{A^{(2)}} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -2 \\ 6 \\ 8 \end{pmatrix}$$

on remarque que $\max_{i \geq k} \left| a_{ik}^{(2)} \right| = 4 = a_{22}^{(2)} = a_{32}^{(2)}$alors $L_2^{(2)}$ reste inchangée dans $A^{(3)}$et $L_3^{(3)} = L_3^{(2)} + L_2^{(2)}$, ainsi

$$\underbrace{\begin{pmatrix} 4 & -6 & 0 \\ 0 & 4 & 1 \\ 0 & 0 & 1 \end{pmatrix}}_{A^{(3)}} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} -2 \\ 6 \\ 2 \end{pmatrix},$$

finalement $x_3 = 2$, $x_2 = 1$, $x_1 = 1$ est l'unique solution du système donné.

Algorithm 1.3 (triangularisation de Gauss avec pivot total) *On peut aussi adopter la stratégie du pivot total qui consiste, à chaque étape k à prendre $a_{kk}^{(k)} = \max_{\substack{i>k \\ j \geq k}} \left| a_{ij}^{(k)} \right|$; en d'autres termes, on choisit comme pivot, le coefficient $a_{ij}^{(k)}$ de valeur absolue maximale de la matrice $A^{(k)}$.*

Remarque 1.1 *Parfois, la méthode du pivot total impose un travail sur les colonnes, alors si on fait des échanges de colonnes cela modifie l'ordre des composantes du vecteur solution x donc il faut penser à rétablir le bon ordre des composantes à la fin.*

1.1.3 Méthode de Facorisation LU

La décomposition de LU est une autre approche visant à exploiter les systèmes triangulaires, en effet le principe de cette méthode est de se ramener à deux systèmes triangulaires.

Définition 1.2 *Etant donnée $A \in M_n(\mathbb{K})$, (l'ensemble des matrices carrées d'ordre n dont les coefficients sont dans le corps $\mathbb{K}$). Les mineurs fondamentaux $(D_k)_{k=1,...,n}$ de la martice $A = (a_{ij})_{1\leq i,j\leq n}$ sont les déterminants des sous-matrices de A formées par les k premières lignes et les k premières colonnes de A, en d'autres termes $D_k = \det\left((a_{ij})_{1\leq i,j\leq k}\right)$ pour $k = 1, ..., n$.*

Soit alors le système linéaire suivant :

$$Ax = b,$$

où A est une matrice carrée d'ordre n dont tous les mineurs fondamentaux sont non nuls, alors pour sa résolution on procède par les étapes suivantes

1. **Décomposition de A** : Dans cette étape on décompose la matrice A en $A = LU$ où L est triangulaire inférieure à diagonale unité et U triangulaire supérieure, ainsi : résoudre $Ax = b$ revient à résoudre $LUx = b$.
2. **Résolution du système triangulaire inférieur** : On pose $y = Ux$, on aura $Ly = b$ que l'on résout facilement (par descente).
3. **Résolution du système triangulaire supérieur** : $Ux = y$ (par remontée).

Théorème 1.1 *Etant donnée une matrice carrée et inversible A d'ordre n et à coéfficient dans $\mathbb{K}$, dont tous les mineurs fondamentaux sont non nuls, alors Il existe un unique couple de matrices (L, U), avec $U = (u_{ij})_{1\leq i,j\leq n}$ triangulaire supérieure (comme "UPPER", et $L = (l_{ij})_{1\leq i,j\leq n}$ triangulaire inférieure (comme "LOWER") à diagonale unité (appelée décomposition de Doolittle), tel que $A = LU$.*

Proposition 1.1 *La factorisation LU de la matrice carrée A d'ordre n existe si et seulement si les sous-matrices principales $A_i = (a_{hk})_{h,k=1,...,i}$, sont inversibles. Cette propriété est satisfaite en particulier dans les cas qui suivent :*

a- *Si A est une matrice symétrique définie positive (voir définition 1.3 et théorème 1.2)*

b- *Si A est une matrice à diagonale strictement dominante par lignes, c'est-à-dire*

$$|a_{ii}| > \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}| \text{ pour tout } i = 1, ..., n;$$

c- *Si A est une matrice à diagonale strictement dominante par colonnes, c'est-à-dire*

$$|a_{jj}| > \sum_{\substack{i=1 \\ j\neq i}}^{n} |a_{ij}| \text{ pour tout } i = 1, ..., n.$$

Si A est inversible, sa factorisation LU est unique.

Algorithm 1.4 (de la méthode LU (décomposition de Doolitle)) *Etant donné une matrice carrée $A = (a_{ij})_{1\leq i,j\leq n}$ d'ordre n, admettant une décomposition LU avec $U = (u_{ij})_{1\leq i,j\leq n}$ triangulaire supérieure et $L = (l_{ij})_{1\leq i,j\leq n}$ triangulaire inférieure à diagonale unité, alors*

$$\begin{cases} \text{Pour tout } \ k = 1, ...n, \\ u_{km} = a_{km} - \sum_{j=1}^{k-1} l_{kj}u_{jm} \text{ pour } m = k, k+1, ..., n \text{ ce qui définit la } k^{ème} \text{ rangée de } U. \\ l_{ik} = \frac{a_{ik} - \sum_{j=1}^{k-1} l_{ij}u_{jk}}{u_{kk}} \ \text{ pour } i = k+1, k+2, ..., n \text{ et } l_{ii} = 1 \text{ce qui définit la } k^{ème} \text{ colonne de } L. \end{cases}$$

Exemple 1.5 *Pour un exemple moins général, on suppose qu'on veut trouver une factorisation LU de la matrice*

$$A = \begin{pmatrix} 2 & 3 & 2 \\ 1 & 3 & 2 \\ 3 & 4 & 1 \end{pmatrix}$$

On suppose d'abord qu'il existe une factorisation de LU de A. Ensuite, on a ceci :

$$A = \begin{pmatrix} 2 & 3 & 2 \\ 1 & 3 & 2 \\ 3 & 4 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ l_{21} & 1 & 0 \\ l_{31} & l_{32} & 1 \end{pmatrix} \begin{pmatrix} u_{11} & u_{12} & u_{13} \\ 0 & u_{22} & u_{23} \\ 0 & 0 & u_{33} \end{pmatrix},$$

on a alors

$$u_{11} = 2, \quad u_{12} = 3, \quad u_{13} = 2,$$

en passant à la deuxième rangée de A, on a :

$$2l_{21} = 1, \ 3l_{21} + u_{22} = 3, \quad 2l_{21} + u_{23} = 2,$$

ainsi, on a $l_{21} = \frac{1}{2}$, $u_{22} = \frac{3}{2}$, $u_{23} = 1$ et puis en passant à la troisième rangée de A on trouve

$$2l_{31} = 3, \quad 3l_{31} + \frac{3}{2}l_{32} = 4, \quad 2l_{31} + l_{32} + u_{33} = 1,$$

ainsi, on a $l_{31} = \frac{3}{2}$, $l_{32} = -\frac{1}{3}$ et $u_{33} = -\frac{5}{3}$. Finalement

$$A = \begin{pmatrix} 2 & 3 & 2 \\ 1 & 3 & 2 \\ 3 & 4 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ \frac{3}{2} & -\frac{1}{3} & 1 \end{pmatrix} \begin{pmatrix} 2 & 3 & 2 \\ 0 & \frac{3}{2} & 1 \\ 0 & 0 & -\frac{5}{3} \end{pmatrix} = LU.$$

Remarque 1.2 *Dans le théorème précédent si c'est la matrice triangulaire supérieure U qui est unitaire et L est triangulaire inférieure alors la décomposition LU est dite décomposition de Croût*

La décomposition LU permet de calculer facilement le déterminant de A, qui est égal au produit des éléments diagonaux de la matrice U. En effet : $\det(A) = \det(LU) = \det(L)\det(U) = 1 \times \det(U) = \prod_{i=1}^{n} u_{ii}$.

La décomposition LU permet aussi de calculer l'inverse de la matrice A, en effet, si A est une matrice carrée d'ordre n inversible, on note par $V^{(1)}, ..., V^{(n)}$, les vecteurs colonnes

de sa matrice inverse, i.e. $A^{-1} = (V^{(1)}, ..., V^{(n)})$.*La relation* $AA^{-1} = \mathbb{I}_n$ *(où* $\mathbb{I}_n$ *est la matrice identité d'ordre* n*) se traduit par les* n *systèmes suivants*

$$AV^{(k)} = e^{(k)}, \quad k = 1, ..., n \tag{1.3}$$

où $e^{(k)}$ *est le vecteur colonne ayant tous les éléments* 0 *sauf celui sur la ligne* k *qui est égal à* 1,*i.e.*

$$e^{(k)} = \begin{pmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{pmatrix} \longrightarrow k^{ème} \text{ ligne}.$$

Une fois connues les matrices L *et* U *qui factorisent la matrice* A*, résoudre les* n *systèmes* (1.3).

1.1.4 Méthode de Factorisation de Cholesky

Dans ce paragraphe on va traiter le cas particulier des matrices symétriques défénies positives. Pour de telles matrices, la factorisation de Cholesky consiste à décomposer A sous la forme LL^t où L est encore ici une matrice triangulaire inférieure. La matrice triangulaire supérieure U de la décomposition LU est ainsi remplacée par la matrice transposée de L. Si on souhaite résoudre un système linéaire, on procède encore ici en deux étapes.On résout d'abord le système triangulaire inférieur $Ly = b$ et ensuite le système triangulaire supérieur $L^t x = y$.

Définition 1.3 *Une matrice symétrique ; i.e.,* $A = A^t$ *(où* A^t *est la transposée de* A*) est dite définie positive si le produit scalaire de tout vecteur* x *avec* Ax *est strictement positif, i.e.*

$$Ax.x > 0 \quad \forall x \neq 0.$$

On peut caractériser les matrices définies positives de bien des façons différentes et équivalentes.

Théorème 1.2 *Les énoncés suivants sont équivalents :*

1. *A est une matrice symétrique et définie positive ;*
2. *Toutes les valeurs propres de A sont réelles et strictement positives ;*
3. *Le déterminant des sous-matrices principales de A est strictement positif ;*
4. *Il existe une factorisation de Cholesky* $A = LL^t$.

Preuve. Admise pour ce cours. ■

Algorithm 1.5 (de la méthode de décomposition de Cholesky) *On va maintenant présenter un algorithme permettant d'obtenir la décompostion de cholesky de la matrice A. On*

considère, alors, une matrice carrée $A = (a_{ij})_{1\leq i,j\leq n}$ *d'ordre* n*, symétrique définie positive admettant une décomposition* LL^t *de Cholesky tel que*

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} = \begin{pmatrix} l_{11} & 0 & \cdots & 0 \\ l_{21} & l_{22} & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{pmatrix} \begin{pmatrix} l_{11} & l_{12} & \cdots & l_{1n} \\ 0 & l_{22} & \cdots & l_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ 0 & \cdots & \cdots & l_{nn} \end{pmatrix},$$

on obtient donc l'algorithme de factorisation de Cholesky comme suit

$$\begin{cases} l_{11} = \sqrt{a_{11}}; \\ \text{Première colonne : pour } i \text{ allant de } 2 \text{ à } n : \quad l_{i1} = \frac{a_{i1}}{l_{11}}; \\ \text{Pour } k \text{ allant de } 2 \text{ à } n : \text{Terme diagonal : } \quad l_{kk} = \sqrt{a_{kk} - \sum_{j=1}^{k-1} l_{kj}^2}; \\ \text{Reste de la colonne} : l_{ik} = \frac{a_{ik} - \sum_{j=1}^{k-1} l_{ij} l_{kj}}{l_{kk}} \text{ pour } i \text{ allant de } k+1 \text{ à } n. \end{cases}$$

Exemple 1.6 *On considère la matrice symétrique*

$$A = \begin{pmatrix} 4 & 6 & 2 \\ 6 & 10 & 5 \\ 2 & 5 & 14 \end{pmatrix}.$$

En suivant l'algorithme précédent on aura :

$$\begin{cases} l_{11} = \sqrt{a_{11}} = 2, \\ \text{Première colonne : } \quad \text{pour } i \text{ allant de } 2 \text{ à } 3 : l_{21} = \frac{a_{21}}{l_{11}} = 3 \quad \text{et} \quad l_{31} = \frac{a_{31}}{l_{11}} = 1, \\ \text{Pour } k \text{ allant de } 2 \text{ à } 3 : \text{Terme diagonal : } \quad l_{22} = \sqrt{a_{22} - l_{21}^2} = \sqrt{10 - 3^2} = 1, \quad l_{32} = \frac{a_{32} - l_{31} l_{21}}{l_{22}} = \\ \text{enfin} \quad l_{33} = \sqrt{a_{33} - l_{31}^2 - l_{32}^2} = \sqrt{14 - (1) - (2)^2} = 3. \end{cases}$$

Ce qui revient à écrire

$$A = \begin{pmatrix} 4 & 6 & 2 \\ 6 & 10 & 5 \\ 2 & 5 & 14 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 3 & 1 & 0 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 2 & 3 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 3 \end{pmatrix}.$$

1.2 Conditionnement d'une matrice

Dans ce paragraphe, on va définir la notion de conditionnement d'une matrice, qui peut servir à établir une majoration des erreurs d'arrondi dues aux erreurs sur les données. La notion de conditionnement est également utilisée dans l'étude des méthodes itératives qu'on va voir dans le chapitre suivant. Pour l'étude du conditionnement comme pour l'étude des erreurs, on a besoin d'aborder la notion de norme vectorielle et de rayon spectral, au sens de la définition suivante.

Définition 1.4 *Une norme vectorielle est une application de* $\mathbb{R}^n$ *dans* $\mathbb{R}$ ($\mathbb{R}$ *désigne l'ensemble des réels*) *qui associe à un vecteur* x *un scalaire noté* $\|x\|$ *et qui vérifie les trois propriétés suivantes*

1. *La norme d'un vecteur est toujours strictement positive, sauf si le vecteur a toutes ses composantes nulles,i.e.,*
$$\|x\| > 0 \quad \textit{sauf si } x = 0.$$
2. *Si α est un scalaire, alors*
$$\|\alpha x\| = |\alpha| \, \|x\| ,$$
où $|\alpha|$ est la valeur absolue de α.
3. *L'inégalité triangulaire est toujours vérifiée entre deux vecteurs x et y quelconques ;i.e.,*
$$\|x + y\| \leq \|x\| + \|y\| .$$

On peut définir, plusieurs normes vérifiant les trois propriétés nécessaire comme le montre l'exemple suivant.

Exemple 1.7 – *La norme euclidienne d'un vecteur x qui est notée par $\|x\|_2$ et est définie comme suit :*
$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + ... + x_n^2}.$$
– *La norme l_1 d'un vecteur x qui est notée par $\|x\|_1$ et est définie comme suit :*
$$\|x\|_1 = \sum_{i=1}^{n} |x_i|.$$
– *La norme l_∞ d'un vecteur x qui est notée par $\|x\|_\infty$ et est définie comme suit :*
$$\|x\|_\infty = \max_{1 \leq i \leq n} |x_i| .$$

Etant donné, alors, le vecteur $x = (1, -3, -8)^t$ dans $\mathbb{R}^3$ ainsi
$$\begin{aligned} \|x\|_2 &= \sqrt{1^2 + (-3)^2 + (-8)^2} = \sqrt{74}. \\ \|x\|_1 &= |1| + |-3| + |-8| = 12. \\ \|x\|_\infty &= \max_{1 \leq i \leq n} (|1| , |-3| , |-8|) = 8. \end{aligned}$$

Comme on s'intéresse plus particulièrement aux systèmes linéaires, il importe de pouvoir définir des normes relatives aux matrices.

Définition 1.5 *Une norme matricielle est une application qui associe à une matrice A un scalaire noté $\|A\|$ vérifiant les quatre propriétés suivantes*

1. *La norme d'une matrice est toujours strictement positive, sauf si la matrice a toutes ses composantes nulles ;i.e.,*
$$\|A\| > 0 \quad \textit{sauf si } A = 0.$$
2. *Si α est un scalaire, alors*
$$\|\alpha x\| = |\alpha| \, \|x\| .$$

3. *L'inégalité triangulaire est toujours vérifiée entre deux matrices A et B quelconques ; i.e.,*
$$\|A+B\| \leq \|A\| + \|B\|.$$
4. *Une quatrième propriété est nécessaire pour les matrices*
$$\|AB\| \leq \|A\|.\|B\|.$$

Remarque 1.3 *On peut construire une norme matricielle à partir d'une norme vectorielle quelconque en posant* $\|A\| = \sup_{\|x\|=1} \|Ax\|$ *et on montre que toutes les propriétés d'une norme matricielle sont ainsi vérifiées. Une norme matricielle ainsi construite est appelée norme induite (ou norme subordonnée) par la norme vectorielle.*

Théorème 1.3 *Les normes matricielles induites par les normes vectorielles l_1 et l_∞ sont respectivement données par*

$$\begin{aligned}
\|A\|_1 &= \sup_{\|x\|_1=1} \|Ax\|_1 = \max_{1\leq j\leq n} \sum_{i=1}^{n} |a_{ij}|. \\
\|A\|_\infty &= \sup_{\|x\|_\infty=1} \|Ax\|_\infty = \max_{1\leq i\leq n} \sum_{j=1}^{n} |a_{ij}|. \\
\|A\|_2 &= \sup_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\rho(A^tA)}, \text{ où } \rho(A^tA) \text{ désigne le rayon spectral de } A^tA.
\end{aligned}$$

Exemple 1.8 *Etant donnée la matrice A définie comme suit*

$$A = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -5 \\ 1 & -9 & 0 \end{pmatrix}.$$

ALors
$$\|A\|_1 = \max(5, 12, 10) = 12, \quad et \quad \|A\|_\infty = \max(8, 9, 10).$$

Lorsque l'on s'intéresse aux systèmes linéaires, on doit souvent manipuler des produits de matrices par des vecteurs , d'où l'intérêt de la définition suivante.

Définition 1.6 *Une norme vectorielle et une norme matricielle sont dites compatibles si la condition suivante :*
$$\|Ax\| \leq \|A\| \, \|x\| \tag{1.4}$$
est satisfaite pour toute matrice A et vecteur x.

Exemple 1.9 *On considère le vecteur $x = (1, -3, -8)^t$ et la matrice $A = \begin{pmatrix} 1 & -2 & 5 \\ -3 & 1 & -5 \\ 1 & -9 & 0 \end{pmatrix}$.*

Le produit Ax donne le vecteur
$$Ax = (-33, 34, 28)^t,$$
par suite
$$\|Ax\|_1 = 95, \qquad \|Ax\|_\infty = 34, \qquad \|Ax\|_2 = \sqrt{3029}$$

Et donc l'inégalité (1.4) *devient respectivement*

$$\begin{array}{rcll} 95 & \leq & (12)(12) & \text{en norme } l_1. \\ 34 & \leq & (10)(8) & \text{en norme } l_\infty. \\ \sqrt{3029} & \leq & (\sqrt{147})(\sqrt{74}) & \text{en norme } l_2. \end{array}$$

A présent on va définir la notion de conditionnement d'une matrice. On va introduire d'abord l'exemple classique suivant :

Exemple 1.10 *On considère le système linéaire* $Ax = b$ *avec*

$$A = \begin{pmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{pmatrix}, \quad b = \begin{pmatrix} 32 \\ 23 \\ 33 \\ 31 \end{pmatrix}.$$

On remarque tout d'abord que la matrice A *est symétrique, que* $\det A = 1$ *et que la solution du système* $Ax = b$ *est donnée par* $x = (1, 1, 1, 1)^t$.

- **Premier cas (où b est perturbé)**
  Dans ce cas, on va perturber le second membre b légèrement tel que

$$b' = \begin{pmatrix} 32,1 \\ 22,9 \\ 33,1 \\ 30,9 \end{pmatrix}.$$

  Si on résout le système $Ax' = b'$ on trouve $x' = (9.2,\ -12.6,\ 4.5,\ -1.1)^t$. La « petite » perturbation sur le second membre b entraîne donc une « forte » perturbation sur la solution du système.

D'une façon générale, on considère les deux systèmes

$$Ax = b \qquad \text{et} \qquad A\,(x + \delta x) = (b + \delta b)\,.$$

On a donc $A\delta x = \delta b$ par suite $\delta x = A^{-1}\delta b$, alors, on obtient la majoration suivante de l'erreur absolue sur la solution

$$\|\delta x\| \leq \left\|A^{-1}\right\| \ \|\delta b\|$$

et comme $Ax = b$, alors $\|b\| \leq \|A\|\ \|x\|$. Finalement, on obtient une majoration de l'erreur relative sur la solution en fonction de l'erreur relative sur la donnée comme suit

$$\frac{\|\delta x\|}{\|x\|} \leq \left\|A^{-1}\right\| \ \|A\| \ \frac{\|\delta b\|}{\|b\|}.$$

On note que cette majoration est optimale dans le sens où il n'existe pas de borne plus petite qui soit valable pour tout système. En effet, si on prend

$$A = \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix}, \qquad b = (1, 0)^t \qquad \text{et} \qquad \delta b = (0, \frac{1}{2}).$$

La solution de $Ax = b$ est alors $x = (1, 0)^t$ et celle de $A\delta x = \delta b$ est $\delta x = (1, 0)^t$. On a donc $\frac{\|\delta x\|}{\|x\|} = 1$ et $\frac{\|\delta b\|}{\|b\|} = \frac{1}{2}$. Comme $\|A^{-1}\|\,\|A\| = 2$ alors la borne est atteinte.

– **Premier cas (où A est perturbé)**
De la même façon, si on perturbe légèrement la matrice A et que l'on considère

$$A'' = \begin{pmatrix} 10 & 7 & 8,1 & 7,2 \\ 7,08 & 5,04 & 6 & 5 \\ 8 & 5,98 & 9,89 & 9 \\ 6,99 & 4,99 & 9 & 9,98 \end{pmatrix},$$

alors la solution du système $A''x'' = b$ est $x'' = (-81, 107, -34, 22)^t$.
D'une manière générale, on considère les deux systèmes

$$Ax = b \qquad \text{et} \qquad (A + \Delta A)(x + \delta x) = b,$$

alors, $\delta x = A^{-1}\Delta A(x + \delta x)$, ainsi

$$\frac{\|\delta x\|}{\|x + \delta x\|} \leq \left\|A^{-1}\right\| \ \|A\| \ \frac{\|\Delta A\|}{\|A\|}.$$

Définition 1.7 *Soit $\|.\|$ une norme matricielle induite et A une matrice inversible. Le nombre $Cond(A) = \|A^{-1}\| \ \|A\|$ est dit le conditionnement de A relatif à la norme $\|.\|$. Si la norme considérée est $\|.\|_p$, on notera le conditionnement associé par $Cond_p$.*

Remarque 1.4 *Ce nombre mesure la « sensibilité » de la solution par rapport aux données du problème. Une matrice est dite bien conditionnée si $Cond(A) \simeq 1$ et mal conditionnée si $Cond(A) >> 1$.*

Exemple 1.11 *On considère la matrice $A = \begin{pmatrix} -1 & 2 \\ 2 & -3 \end{pmatrix}$, dont on veut trouver le conditionnement en norme $\|.\|_1$.*

$\|A\|_1 = 5$ et comme $A^{-1} = \begin{pmatrix} 3 & 2 \\ 2 & 1 \end{pmatrix}$, ensuite $\|A^{-1}\|_1 = 5$, ainsi $Cond_1(A) = 25$.

Proposition 1.2 (propriétés générales du conditionnement) *On considère une matrice carrée A d'ordre n, alors les proprités suivantes sont vérifiées :*
- *Si A est une matrice inversible, alors $Cond(A) \geq 1$.*
- *Soit $\alpha \in \mathbb{R}$, alors $Cond(\alpha A) = \alpha Cond(A)$.*
- *Soit B une matrice carrée d'ordre n, alors $Cond(AB) \leq Cond(A)Cond(B)$.*

Proposition 1.3 (propriétés du conditionnement pour la norme$\|.\|_2$) *Soit $\|.\|_2$ la norme définie précédement sur $M_n(\mathbb{R})$ subordonnée à la norme euclidienne sur $\mathbb{R}^n$, donc*

$$Cond_2(A) = \|A\|_2 \, . \, \|A\|_2^{-1},$$

alors, si de plus A est une matrice symétrique définie positive et si $\lambda_{\max}$ (resp $\lambda_{\min}$) sont sa plus grande (resp. petite) valeur propre, on a

$$Cond_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}} = \rho(A)\rho(A^{-1}).$$

1.3 Méthodes itératives

Les méthodes itératives sont utilisées soit pour la résolution de systèmes linéaires de très grande taille, soit lorsque l'on dispose d'une estimation de la solution que l'on veut améliorer. Ces méthodes donnent, en théorie, la solution x d'un système linéaire (1.1) après un nombre infini d'itérations. Ces méthodes itératives de résolution de systèmes linéaires consistent alors à calculer les valeurs successives d'une suite de vecteurs x^n convergeant vers la solution x quand $n \to +\infty$.

Principe : Etant donné le système (1.1) à résoudre. Le principe des méthodes itératives de résolution de systèmes linéaires consiste à décomposer la matrice A en $A = M - N$ où les matrices M, N sont des matrices carrées d'ordre n convenablement choisies et M est inversible. On peut alors réécrire le système $Ax = b$ sous la forme $x = M^{-1}(Nx + b)$ et utiliser, si elle converge, la méthode itérative suivante :

$$\begin{cases} x^{(k+1)} = M^{-1}(Nx^{(k)} + b), & k \geq 0, \\ x^{(0)} \qquad \text{un vecteur initial} \end{cases} \tag{1.5}$$

L'idée est de choisir une matrice M particulièrement facile à inverser. Quand on dit que la matrice M est facile à inverser, on ne veut pas dire que l'on calcule effectivement M^{-1}. Ce qu'on aura à calculer c'est la solution du système linéaires dont la matrice est M.

Définition 1.8 *On dit que la méthode itérative* (1.5) *est convergente si quel que soit le vecteur initial $x^{(0)} \in \mathbb{R}^n$ et quel que soit le second membre $b \in \mathbb{R}^n$, la suite $\left(x^{(k)}\right)_{k\geq 0}$ définie par la méthode* (1.5) *converge vers $x = A^{-1}b$.*

Critère de Convergence

Lemme 1.1 *Si la méthode itérative* (1.5) *est convergente et si on note $x = A^{-1}b$ la solution, alors*

$$x^{(k)} - x = M^{-1}N(x^{(0)} - x).$$

Preuve. On a

$$M^{-1}b = (\mathbb{I}_n - M^{-1}N)A^{-1}b = (\mathbb{I}_n - M^{-1}N)x,$$

d'où

$$x^{(k+1)} = M^{-1}Nx^{(k)} + (\mathbb{I}_n - M^{-1}Nb)x,$$

ou encore

$$x^{(k+1)} - x = M^{-1}N(x^{(k)} - x),$$

d'où le résultat. ■

Théorème 1.4 *Les assertions suivantes sont équivalentes :*

1. *La méthode itérative* (1.5) *est convergente,*
2. *Pour tout $y \in \mathbb{k}^n$, $\lim\limits_{k\to+\infty} \left(M^{-1}N\right)^{(k)} y = 0$,*
3. *Pour toute norme matricielle $\|.\|$ sur $M_n(\mathbb{k})$, on a $\lim\limits_{k\to+\infty} \left\|\left(M^{-1}N\right)^{(k)}\right\| = 0$.*

Preuve. Admise. ■

En pratique, les caractérisations précédentes de la convergence d'une méthode itérative ne sont pas faciles à vérifier. On utilise plutôt le résultat suivant :

Théorème 1.5 *(Les assertions suivantes sont équivalentes :*

1. *La méthode itérative* (1.5) *est convergente,*
2. $\rho(M^{-1}N) < 1$, *où* $\rho\,(M^{-1}N)$ *désigne le rayon spectral de la matrice* $M^{-1}N$, *i.e., le maximum des modules des valeurs propres de* $M^{-1}N$,
3. *Il existe une norme matricielle* $\|.\|$ *sur* $M_n(\mathbb{k})$, *subordonnée à une norme vectorielle sur* $\mathbb{k}^n$ *telle que* $\|M^{-1}N\| < 1$.

Preuve. Admise. ■

Il y a une infinité de choix possibles pour M et N vérifiant $A = M - N$, on va en donner trois à titre d'exemples classiques : les méthodes de Jacobi, Gauss-Seidel et de relaxation. Le point de départ de chacune de ces méthodes est l'unique décomposition de la matrice $A = (a_{ij})_{1\leq i,j\leq n}$ d'ordre n sous la forme $A = D - E - F$ avec :

1. $D = (d_{ij})_{1\leq i,j\leq n}$ diagonale, tel que $d_{ii} = a_{ii}$ et $d_{ij} = 0$ pour $i \neq j$,
2. $E = (e_{ij})_{1\leq i,j\leq n}$ triangulaire inférieure stricte telle que $e_{ij} = -a_{ij}$ si $i > j$ et $e_{ij} = 0$ si $i \leq j$,
3. $F = (f_{ij})_{1\leq i,j\leq n}$ triangulaire supérieure stricte telle que $f_{ij} = -a_{ij}$ si $i < j$ et $f_{ij} = 0$ si $i \geq j$.

Exemple 1.12 *On considère la matrice*

$$A = \begin{pmatrix} 2 & -1 & 1 \\ 2 & 2 & 2 \\ -1 & -1 & 2 \end{pmatrix}. \tag{1.6}$$

La décomposition de A sous la forme $A = D - E - F$ *décrite ci-dessus s'écrit alors*

$$A = \begin{pmatrix} 2 & -1 & 1 \\ 2 & 2 & 2 \\ -1 & -1 & 2 \end{pmatrix} = \underbrace{\begin{pmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{pmatrix}}_{D} - \underbrace{\begin{pmatrix} 0 & 0 & 0 \\ -2 & 0 & 0 \\ 1 & 1 & 0 \end{pmatrix}}_{E} - \underbrace{\begin{pmatrix} 0 & 1 & -1 \\ 0 & 0 & -2 \\ 0 & 0 & 0 \end{pmatrix}}_{F}$$

On supposera de plus que D est inversible et on distingue les trois méthodes suivantes :

1.3.1 Méthode de Jacobi

On remarque que si les éléments diagonaux de sont non nuls, le système linéaire (1.1) ($Ax = b$) est équivalent à :

$$x_i = \frac{1}{a_{ii}}\left(b_i - \sum_{j=1, j\neq i}^{n} a_{ij}x_j\right), \qquad i = 1, ..., n.$$

Pour un vecteur initial $x^{(0)}$ choisi, on calcule $x^{(k+1)}$ par

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1, j\neq i}^{n} a_{ij} x_j^{(k)} \right), \qquad i = 1, ..., n$$

Cela permet d'identifier la décomposition suivante de A :

$$M = D \quad \text{et} \quad N = E + F.$$

L'avantage de cette méthode est que dans ce cas là, M est très facile à inverser. On considère le système linéaire (1.1) avec A inversible, le schéma itératif s'écrit :

$$\begin{aligned} Dx^{(k+1)} &= (E+F)x^{(k)} + b \quad \text{pour } k \geq 0 \\ &\Longleftrightarrow \\ x^{(k+1)} &= D^{-1}(E+F)x^{(k)} + D^{-1}b \quad \text{pour } k \geq 0. \end{aligned} \tag{1.7}$$

Définition 1.9 *On appelle la matrice $B_J = D^{-1}(E+F)$,matrice de Jacobi associée à A.*

Exemple 1.13 *Pour la matrice A donnée par* (1.6)*, on obtient*

$$B_J = D^{-1}(E+F) = \begin{pmatrix} 0 & \frac{1}{2} & -\frac{1}{2} \\ -1 & 0 & -1 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{pmatrix}.$$

Les valeurs propres de la matrice B_J sont 0 et $\pm\frac{i\sqrt{5}}{2}$. D'après le théorème 1.5, la méthode de Jacobi diverge car $\rho(B_J) = \frac{\sqrt{5}}{2} > 1$.

1.3.2 Méthode de Gauss Seidel

On a vu la méthode d'itération de Jacobi pour résoudre un système d'équations linéaires (1.1). On va maintenant examiner une autre méthode connue sous le nom de méthode d'itération de Gauss-Seidel qui est en quelque sorte une amélioration de la méthode d'itération de Jacobi, en effet ; la méthode de Gauss-Seidel diffère de la méthode de Jacobi par le fait qu'à la $(k+1)^{ieme}$ étape les valeurs $x_i^{(k+1)}$ déjà calculées sont utilisées pour mettre à jour la solution,i.e., dans la méthode de Gauss-Seidel les valeurs calculées sont utilisées au fur et à mesure du calcul et non à l'issue d'une itération comme dans la méthode de Jacobi. Ainsi,

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)} \right), \qquad i = 1, ..., n.$$

Cette méthode revient à effectuer la décomposition suivante de la matrice A :

$$M = D - E \quad \text{et} \qquad N = F.$$

Le schéma itératif s'écrit alors

$$\begin{aligned} (D-E)x^{(k+1)} &= Fx^{(k)} + b \quad \text{pour } k \geq 0 \\ &\Leftrightarrow \\ x^{(k+1)} &= (D-E)^{-1}Fx^{(k)} + (D-E)^{-1}b\ . \end{aligned}$$

Définition 1.10 *On appelle la matrice $B_{GS} = (D-E)^{-1}F$, matrice de Gauss Seidel associée à A.*

Exemple 1.14 *Pour la matrice A donnée par* (1.6)*, on obtient*

$$(D-E)^{-1}F = \begin{pmatrix} 0 & \frac{1}{2} & -\frac{1}{2} \\ 0 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & 0 & -\frac{1}{2} \end{pmatrix}.$$

Les valeurs propres de la matrice B_{GS} sont 0 et $-\frac{1}{2}$ (de multiplicité 2). D'après le théorème 1.5, la méthode de Gauss Seidel converge car $\rho(B_J) = \frac{1}{2} < 1$.

1.3.3 Méthode de Relaxation

On considère un système linéaire (1.1) où A est inversible. Soit ω un nombre réel non nul, appelé par la suite paramètre de la méthode de relaxation. La décomposition de la matrice A se fait de la manière suivante

$$M = \frac{1}{\omega}(D - \omega E) \text{ qui est inversible} \qquad \text{et } N = \left(\frac{1-\omega}{\omega}\right) D + F.$$

La méthode de relaxation s'exprime alors par la suite itérative

$$\begin{aligned} \frac{1}{\omega}(D-\omega E)\, x^{(k+1)} &= \left[\left(\frac{1-\omega}{\omega}\right) D + F\right] x^{(k)} + b \text{ pour } k \geq 0 \\ &\Leftrightarrow \\ x^{(k+1)} &= (D-\omega E)^{-1}\left[(1-\omega)\, D + \omega F\right] x^{(k)} + \omega (D-\omega E)^{-1} b. \end{aligned}$$

Définition 1.11 *La matrice $B_R(\omega) = (D-\omega E)^{-1}\left[(1-\omega)\, D + \omega F\right]$ s'appelle la matrice de relaxation associée à A et ω est le facteur ou paramettre de relaxation.*

- *Si $\omega < 1$, on dit sous-relaxation.*
- *Si $\omega = 1$, on retrouve la méthode de Gauss-Seidel.*
- *Si $\omega > 1$, on parle de sur-relaxation.*

Exemple 1.15 *Pour la matrice A donnée par* (1.6)*, on obtient*

$$B_R(\omega) = \begin{pmatrix} 1-\omega & \frac{1}{2}\omega & -\frac{1}{2}\omega \\ \omega\,(1-\omega) & -\frac{1}{2}\omega^2 + 1 - \omega & \frac{1}{2}\omega^2 - \omega \\ \frac{1}{2}\omega\,(\omega-1)^2 & -\frac{1}{4}\omega^3 - \frac{1}{4}\omega^2 + \frac{1}{2}\omega & \frac{1}{4}\omega^3 - \frac{3}{4}\omega^2 + 1 - \omega \end{pmatrix}.$$

Il est évident que la convergence de la méthode de relaxation dépendra de la valeur de ω, du fait que les valeurs propres de la matrice $B_R(\omega)$ dépendent en général de ω.

Théorème 1.6 *La condition nécessaire de convergence de la méthode de relaxation est $0 < \omega < 2$.*

Preuve. On a

$$B_R(\omega) = \frac{1}{\omega}(D-\omega E)^{-1}\left(\frac{1-\omega}{\omega} D + F\right).$$

On note par $\lambda_i(\omega)$, les valeurs propres de $B_R(\omega)$, on a

$$\det\left(B_R(\omega)\right) = \prod_{i=1}^{n} \lambda_i(\omega) = \frac{\det\left(\frac{1-\omega}{\omega}D + F\right)}{\det \frac{1}{\omega}(D - \omega E)} = (1-\omega)^n .$$

D'où $\rho(B_R(\omega)) \geq \left(|1-\omega|^n\right)^{\frac{1}{n}} = |1-\omega|$.

Pour que la méthode de relaxation converge, il est nécessaire d'avoir $|1-\omega| < 1$ d'où $0 < \omega < 2$. ■

Ces trois méthodes convergeront donc si le rayon spectral de la matrice d'itérations associée pour chaque méthode est inférieur à 1(voir 1.5). Cependant, on sait que le calcul du rayon spectral d'une matrice est un problème difficile, surtout si la matrice est de grande taille. Il existe alors des types de matrices qui vérifient automatiquement la condition de convergence de la méthode correspondante, autrement dit, il existe des types spéciales de matrices pour lesquelles il est possible de préciser a priori quelques résultats de convergence pour les méthodes itératives examinées précédement. Le premier résultat dans cette direction est le suivant.

Définition 1.12 *Une matrice carrée $A = (a_{ij})_{1\leq i,j\leq n}$ d'ordre n est dite à diagonale strictement dominante si*

$$|a_{ii}| > \sum_{j=i,\ j\neq i}^{n} |a_{ij}| \ \textit{pour tout}\ i = 1, ..., n.$$

Exemple 1.16 *La matrice* $A = \begin{pmatrix} 6 & 4 & -3 \\ 4 & -2 & 0 \\ -3 & 0 & 1 \end{pmatrix}$ *est à diagonale strictement dominante.*

Théorème 1.7 *Si A est une matrice à diagonale dominante stricte, alors les méthodes de Jacobi et de Gauss Seidel sont convergentes (donc en particuler la méthode de relaxation pour $\omega \approx 1$)..*

Preuve. On va montrer ce théorème pour la méthode de Jacobi et on laisse à traiter la suite pendant les travaux dirigés.

D'après (1.7) la méthode de Jacobi s'écrit

$$x^{(k+1)} = D^{-1}(E+F)x^{(k)} + D^{-1}b\ ,$$

et donc la matrice d'itération est $B_J = (B_{ij})_{1\leq i,j\leq n}$ tel que

$$B_J = D^{-1}(E+F),$$

avec

$$B_{ij} = \left(\frac{-a_{ij}}{|a_{ii}|}\right) \text{ si } i \neq j \text{ et } B_{ii} = 0$$

Puisque A est à diagonale dominante, on a

$$\left\|D^{-1}(E+F)\right\|_\infty = \max_{1\leq i\leq n}\left(\frac{1}{|a_{ii}|}\sum_{j=1,\ j\neq i}^{n} |a_{ij}|\right) < 1,$$

finalement la méthode de Jacobi est convergente. ■

Théorème 1.8 *Etant donnée une matrice $A = (a_{ij})_{1\leq i,j\leq n}$ d'ordre n, à diagonale strictement dominante, alors le facteur ω de la méthode de relaxation est tel que $0 < \omega \leq 1$ et elle converge.*

indication. Montrer que si λ est une valeur propre de $B_R(\omega)$, puis supposer que $|\lambda| \geq 1$ ensuite majorer $|\lambda + \omega - 1|$ (en utilisant le théorème dde Gerschgorin), et enfin majorer $|\lambda|$. Puis en déduire. ■

Un autre résultat intéressant pour les applications, concerne les matrices symétriques définies positives.

Théorème 1.9 *Soit $A = (a_{ij})_{1\leq i,j\leq n}$ une matrice symétrique réelle, définie, positive et d'ordre n. On la décompose sous la forme $A = M - N$, où M est inversible. Alors,*

1. *$M^t + N$ est symétrique,*
2. *Si de plus $M^t + N$ est définie positive, alors $\rho(M^{-1}N) < 1$.*

Applications

- Si A est symétrique, si A et $2D - A$ sont définies positives alors la méthode de Jacobi converge.
- Si A est une matrice symétrique définie positive, alors la méthode de Gauss-Seidel est convergente (la méthode de Jacobi ne l'est pas forcément).
- Si A est symétrique définie positive, et si $0 < \omega < 2$, alors la méthode de relaxation converge.