TEXTE **: Les IA génératives et hallucinations**

Nous sommes le 4 juin 2024 en plein tournoi de tennis de Roland-Garros. Après son forfait, le tennisman Novak Djokovic annonce son opération au genou mais bizarrement, pour l'outil d'intelligence artificielle (IA) ChatGPT 4, il « va bien. (…) Il a eu quelques blessures par le passé mais s'est bien rétabli ». A l'inverse, pour ChatGPT, son rival Zverevev est blessé à la cheville – une entorse en réalité guérie en 2022. Ce n'est qu'un exemple, mais il illustre bien l'un des défauts-clés des IA textuelles génératives : elles « hallucinent ».

[En 2023, le dictionnaire anglais Cambridge a désigné hallucinate (halluciner) comme « mot de l'année » dans le contexte de l'IA**]**. **[**Un système d'IA qui hallucine produit de l'information partiellement ou complètement fausse en la présentant comme si elle était authentique et correspondait à la requête**]**. La reconnaissance officielle du terme en dit long sur ce phénomène, qui peut étonner quand on pense aux prouesses d'outils comme ChatGPT. Mais le fait est qu'on ne peut jamais se fier entièrement au contenu créé par l'IA générative. La même prudence s'impose avec les outils d'IA de traduction. Tous ces outils ont des hallucinations, souvent difficilement repérables.

L'IA générative se distingue par sa capacité à produire du texte ou des images en se basant sur des modèles d'apprentissage créés à partir des données qu'elle a précédemment traitées. Ce processus est similaire à l'apprentissage humain par le mimétisme : **[**tout comme, nous nous basons sur nos expériences passées pour comprendre et anticiper de nouvelles situations, l'IA générative s'appuie sur les données qu'elle a déjà vues pour générer des résultats**]**.

D'une part, l'un des principaux avantages des Intelligences artificielles (IA) génératives est sa capacité à traiter rapidement de grandes quantités de données textuelles. Grâce à des algorithmes de traitement du langage naturel (NLP), l'IA peut analyser de grands volumes de textes qui permet un gain de temps pour les usagers lors du tri des informations. De plus, ces algorithmes jouent également un rôle dans l'amélioration de la qualité rédactionnelle. Ils sont capables de détecter et de corriger les erreurs grammaticales et les incohérences dans les textes, garantissant ainsi des documents sans aucune erreur.

[D'autre part, il est important de reconnaitre que l'IA, malgré ses grandes capacités, a ses limites**]**. En effet, des "hallucinations" d'IA se produisent lorsqu'un modèle d'apprentissage génère des informations incorrectes en raison d'un manque de contexte ou d'informations récentes. Dans sa tentative de fournir une réponse, l'IA peut générer des interprétations erronées, entraînant ainsi une hallucination.

Malgré leur appellation, les outils d'intelligence artificielle ne réfléchissent pas. Leurs algorithmes fonctionnent à partir de corpus de contenus existants, dont ils extraient la réponse la plus probable à une question ou la traduction la plus probable d'un terme ou d'une phrase. Plus une combinaison de mots apparaît souvent dans son corpus, plus l'algorithme la choisit de préférence à d'autres combinaisons moins fréquentes. L'immensité des corpus fait leur force, mais aussi leur faiblesse. Pour les outils d'IA publics, des masses de contenus originaux ou traduits sont recueillies partout sur Internet sans vérification. Il y a beaucoup d'erreurs linguistiques ou factuelles, de fausses informations, de stéréotypes, de manques d'uniformité, etc.

Les hallucinations sont aussi réelles en IA de traduction. Un outil qui ne trouve pas de traduction sûre ne peut pas vous prévenir ni vous consulter pour bien interpréter un passage. Il laisse parfois des parties de texte non traduites. Mais en général, il propose une traduction qui risque d'être factuellement erronée même si elle est linguistiquement exacte.

Texte adapté à partir des sites versacom.ca, lemonde.fr, misgroup.io (mai, juin 2024)

CORRIGÉ

Ecole Nationale Polytechnique d'Oran – Maurice Audin
ENP Oran – Département des FPST
CORRIGE Examen n° 1 – Module de Techniques d'expression 1 – 2è année FPST

Nom : ..... **Prénom :** ..... **Groupe :** .....

Identifiant : .....

Durée de l'examen : 1 heure 15 min **Date :** lundi 20 janvier 2025

Questions :

1. Cochez la ou les bonne(s) réponse(s) : (2 pts)

- **Parmi les différentes propositions, lesquelles correspondent à la problématique centrale du texte ?**

☒ La capacité des IA à générer du contenu original pose la question de la véracité des informations produites.
☐ L'intelligence artificielle redéfinit les exigences et les opportunités sur le marché du travail.
☐ L'intelligence artificielle transforme profondément les pratiques artistiques et créatives.
☒ Les erreurs générées par les intelligences artificielles présentent une source d'inquiétude.
☐ Le défi majeur de l'IA est de concilier progrès technologique et respect de la propriété intellectuelle.

- **Parmi les propositions suivantes, quelles sont celles qui soutiennent la position de l'auteur ?**

☒ Il faut rester vigilant face aux contenus générés par les IA, qu'il s'agisse de textes ou de traductions.
☐ Les "hallucinations" sont des exceptions qui ne remettent pas en question l'efficacité générale des IA.
☐ L'immense capacité de traitement de données par l'IA dépasse largement celle des humains, rendant leurs erreurs négligeables au vu des bénéfices apportés.
☒ L'IA est capable de traiter rapidement de grandes quantités de données et d'améliorer la qualité rédactionnelle des textes grâce à des algorithmes sophistiqués.

2. Pourquoi le mot « hallucinate » a-t-il été choisi comme mot de l'année en 2023 par Cambridge ? (2 pts)

Parce qu'on ne peut jamais se fier entièrement au contenu créé par l'IA générative ainsi que les outils d'IA de traduction.

Réponse complémentaire : *Ainsi le phénomène des « hallucinations » est devenu un enjeu central pour comprendre les limites et les dangers potentiels de l'IA.*

3. Quels sont les éléments qui permettent aux IA de générer des réponses ? (2 pts)

Les IA s'appuient sur d'immenses bases de données (corpus) et des algorithmes de traitement du langage naturel pour générer leurs réponses.

4. Comment l'immensité des corpus constitue-t-elle à la fois une force et une faiblesse pour les IA génératives ? (2 pts)

- Des masses de contenus originaux ou traduits sont recueillies partout sur internet sans vérification.
- Il y beaucoup d'erreurs linguistiques ou factuelles, de fausses informations, de stéréotypes, de manques d'uniformité.

Remarque : *L'immensité de corpus ne fait pas systématiquement sa force.*

CORRIGE

5. A partir du texte, identifiez le paragraphe qui comporte le sujet amené (mentionnez explicitement les phrases de début et de fin de l'extrait sans écrire le paragraphe complet) : (2 pts)

Paragraphe 1 :

« Nous sommes le 4 juin 2024 en plein tournoi de tennis de Roland-Garros. …… Ce n'est qu'un exemple, mais il illustre bien l'un des défauts-clés des IA textuelles génératives : elles « hallucinent ».

6. Dans les extraits suivants, remplacez le connecteur logique souligné par un autre de même valeur : (2 pts)

- **De plus** (……), ces algorithmes jouent également un rôle dans l'amélioration de la qualité rédactionnelle. → ***De surcroît, de même, aussi, en outre, encore, …***

- **D'une part** (….), l'un des principaux avantages des Intelligences artificielles (IA) génératives est sa capacité à traiter rapidement de grandes quantités de données textuelles. **D'autre part** (……), il est important de reconnaitre que l'IA, malgré ses grandes capacités, a ses limites.

→ ***Premièrement, deuxièmement // d'abord, ensuite // en premier lieu, en second lieu // non seulement, mais encore.***

- Mais en général, il propose une traduction qui risque d'être factuellement erronée **même si** (…….) elle est linguistiquement exacte. → ***bien qu'elle, alors qu'elle, or, tandis qu'elle***

7. Précisez le ou les procédé(s) argumentatif(s) utilisé(s) dans les phrases qui sont délimitées par des crochets « [ ] » dans le texte : (4 pts)

- « En 2023, le dictionnaire anglais Cambridge a désigné hallucinate (halluciner) comme « mot de l'année » dans le contexte de l'IA ».

  ☞ **Procédé(s) argumentatif(s) :** ***Fait, appel à l'autorité.***

- « Un système d'IA qui hallucine produit de l'information partiellement ou complètement fausse en la présentant comme si elle était authentique et correspondait à la requête ».

  ☞ **Procédé(s) argumentatif(s) :** ***définition***

- « … tout comme nous nous basons sur nos expériences passées pour comprendre et anticiper de nouvelles situations, l'IA générative s'appuie sur les données qu'elle a déjà vues pour générer des résultats ».

  ☞ **Procédé(s) argumentatif(s) :** ***analogie***

- « D'autre part, il est important de reconnaitre que l'IA, malgré ses grandes capacités, a ses limites ».

  ☞ **Procédé(s) argumentatif(s) :** ***réfutation (concession)***

CORRIGÉ

8. Production écrite (4 pts)

Dans quelques lignes (10 maximum), proposez une conclusion au texte en mettant en avant une solution pour minimiser les risques d'erreurs liés aux hallucinations générées par une IA générative ou de traduction.

Proposition de réponse :

Pour conclure, l'IA générative se révèle être un outil puissant pour la recherche et la création de données offrant une capacité d'analyse rapide et efficace. Toutefois, son utilisation ne doit pas occulter ses limites, notamment en matière d'hallucinations, où l'expertise humaine reste irremplaçable. De ce fait, il est plus judicieux d'associer l'intelligence humaine à celle de l'IA pour tirer pleinement profit de ces technologies afin de minimiser les risques liés à la désinformation.

CORRIGE